

¿Cómo predice un LLM?


Cómo transforma el contexto en probabilidades y genera una respuesta token a token.

EN UNA FRASE Un LLM estima qué token podría seguir al contexto, elige uno y repite el proceso.

EL BUCLE DE GENERACIÓN


01 Una elección cada vez

El token elegido se añade al contexto. Entonces el modelo vuelve a calcular qué podría venir después.



DE DÓNDE SALE ESA CAPACIDAD

02 Practica completando secuencias



Esquema simplificado: durante la generación, los parámetros ya entrenados normalmente permanecen fijos.

03

ELEGIR NO SIEMPRE ES ESCOGER EL

MÁXIMO

La decodificación cambia la respuesta

La misma distribución puede producir salidas distintas según la estrategia configurada.



EL LÍMITE IMPORTANTE

Probable no significa verdadero

El modelo optimiza la continuación del texto, no comprueba automáticamente los hechos. Una respuesta puede sonar coherente y aun así ser falsa.

fluidez ≠ veracidad